

Analisi del Mental Health Score e del Social Media Addiction Score

Nicoletti Fabio Samuele e Oliva Morena

Dipartimento di Scienze Umane e Sociali, Università del Salento, Lecce

Abstract

Il presente studio indaga l'impatto dell'utilizzo dei social media sul benessere psicofisico della popolazione studentesca di età compresa tra i 16 e i 25 anni, analizzando le determinanti del punteggio di salute mentale (Mental Health Score) e del punteggio di dipendenza (Addicted Score). La ricerca si basa sul dataset cross-sectional "Student Social Media & Relationships" (2025), comprendente 705 osservazioni globali.

Dal punto di vista metodologico, dopo aver effettuato una selezione delle variabili tramite gli algoritmi Sequential Replacement e Boruta, l'analisi ha evidenziato i limiti della regressione lineare multipla (violazione dell'omoschedasticità e natura discreta dei dati). Di conseguenza, sono stati adottati Modelli Lineari Generalizzati (GLM) con distribuzione Quasi-Poisson e funzione di legame logaritmica, che hanno garantito stime robuste e una corretta gestione della varianza.

I risultati indicano che il modello per la salute mentale spiega oltre il 70% della variabilità. Si osserva una netta gerarchia del rischio legata all'architettura delle piattaforme: i social basati sul confronto visivo e sullo scorrimento infinito (TikTok, Instagram, Snapchat) incidono negativamente sul benessere, mentre le piattaforme di utilità e messaggistica (WhatsApp, X/Twitter) mostrano effetti neutri o positivi. Il modello relativo alla dipendenza digitale spiega circa il 91% della variabilità. In questo contesto, il predittore più critico risulta essere l'impatto percepito sulla performance accademica, mentre YouTube emerge come la piattaforma a più alto rischio di utilizzo compulsivo, in contrasto con l'effetto protettivo delle app di messaggistica diretta.

In entrambi i modelli, la qualità del sonno si conferma il principale fattore protettivo biologico. Le conclusioni suggeriscono che la salute digitale non dipenda esclusivamente dal tempo di utilizzo, ma sia il risultato dell'interazione tra i ritmi biologici individuali e le specifiche meccaniche di ingaggio delle diverse piattaforme.

1 Introduzione

Nell'ultimo decennio, l'integrazione pervasiva dei social media nella vita quotidiana ha trasformato radicalmente le dinamiche relazionali e il benessere psi-

cofisico della popolazione giovanile. Per gli studenti di età compresa tra i 16 e i 25 anni, le piattaforme digitali non rappresentano solo uno strumento di comunicazione, ma un ecosistema complesso che influenza la performance accademica, la qualità del sonno e l'equilibrio mentale [33].

Questa fascia d'età si caratterizza per la necessità di esplorare la propria identità e per la riorganizzazione neurobiologica che avviene in quegli anni, fenomeni che rendono gli individui particolarmente vulnerabili all'esordio di disturbi psicopatologici (*ibidem*).

La presente ricerca si basa sul dataset "Student Social Media & Relationships", ottenuto da *Kaggle* [17]. Si tratta di una raccolta di dati *cross-sectional* ottenuta tramite un sondaggio online somministrato nel primo trimestre del 2025. L'obiettivo di questo lavoro è duplice: identificare i predittori critici che influenzano il benessere mentale degli studenti (*Mental_Health_Score*); analizzare i meccanismi che portano all'insorgenza della dipendenza digitale (*Addicted_Score*). A questo scopo verranno effettuate delle analisi esplorative sul dataset e verranno poi impostati i modelli di regressione per ognuna delle variabili target. Si procederà poi ad effettuare l'analisi dell'efficacia dei modelli ottenuti e si discuteranno i risultati.

Di seguito, verranno illustrate le evidenze scientifiche ricavate da una revisione di studi trasversali, longitudinali e meta-analitici sull'argomento.

1.1 *Bergen Social Media Addiction Scale (BSMAS)*

La *Bergen Social Media Addiction Scale* è utilizzata nella misurazione della dipendenza da social media. Questo strumento si basa sul modello biopsicosociale delle dipendenze teorizzato da Griffiths [11]. Questo modello, originariamente sviluppato per le dipendenze comportamentali, sostiene che tutte le forme di dipendenza condividono un nucleo comune di sei componenti: Salienza, Modificazioni dell'umore, Tolleranza, Astinenza, Conflitto, Ricaduta. Queste componenti sono dei veri e propri criteri strutturali: se un comportamento non mostra questo pattern, allora è più corretto parlare di "uso problematico" piuttosto che di "dipendenza" [1].

Il test è composto da sei affermazioni riferite alle esperienze avute nell'ultimo anno, ciascuna valutata su scala Likert da 1 a 5. Il risultato si calcola sommando il punteggio degli item; valori più alti indicano maggiore rischio di dipendenza dai social media [24].

Il test è stato ampiamente validato e accettato da meta-analisi e studi psicometrici. Tuttavia, alcuni autori sostengono che applicare il modello di *addiction* ai social media rischi di patologizzare i comportamenti attuati in contesti in cui l'uso intenso dei social è socialmente richiesto [5], e di confondere l'alta frequenza d'uso con la dipendenza senza distinguere chiaramente tra un uso intenso ma funzionale e un uso disfunzionale [4, 12]. Esiste una controversia riguardo al punteggio di cut-off ottimale per definire la dipendenza; alcuni studi propongono una soglia di 19 su 30 [2], mentre ricerche basate su interviste cliniche suggeriscono un cut-off di 24 o 26 [21].

Infine, il modello di Griffiths non è stato sviluppato tenendo in considerazione le specificità dei social, di conseguenza potrebbe non cogliere alcune dimensioni specifiche come ad esempio le dinamiche di notifica [18], il confronto sociale [32], la ricerca di approvazione [9] e la FOMO [7].

Si è discusso della struttura di questo test poiché i dati che verranno analizzati sono stati raccolti attraverso un sondaggio online i cui item sono stati adattati a partire da quelli di scale validate, in particolare la *BSMAS*.

1.2 Revisione della letteratura sui punteggi di salute mentale in studenti dai 16 ai 25 anni

L'analisi dei dati aggregati rivela un quadro preoccupante della salute mentale studentesca, caratterizzato da un trend di deterioramento che, sebbene mostri lievi segni di stabilizzazione dopo il 2023, rimane su livelli storicamente elevati [14, 15, 31].

Studi su larga scala condotti negli Stati Uniti e in Europa indicano che una porzione sostanziale della popolazione studentesca soddisfa i criteri per disturbi mentali diagnosticabili [16]. Secondo il *Healthy Minds Study* (2023-2024), circa il 18% degli studenti universitari riporta sintomi di depressione grave e l'11% riferisce ideazione suicidaria nell'ultimo anno [13]. Sebbene questi dati rappresentino un lieve miglioramento rispetto ai picchi del 2022 (23% per la depressione grave), essi segnalano comunque che quasi un quinto degli studenti vive una condizione di sofferenza psichica acuta [31]. In Europa, i dati normativi raccolti su adolescenti spagnoli (12-18 anni) mostrano punteggi medi di depressione che aumentano con l'età, passando da una media di 6.25 nella prima adolescenza a 7.64 nella tarda adolescenza [8]. Questo incremento suggerisce che il passaggio verso l'età adulta e le crescenti responsabilità accademiche agiscono come stressor cumulativi.

1.3 Revisione della letteratura sui punteggi di Dipendenza dai Social Media (SMA) in studenti dai 16 ai 25 anni

L'analisi dei punteggi BSMAS rivela come l'interazione con le piattaforme digitali stia evolvendo da abitudine a potenziale patologia [18]. Questi punteggi non seguono una distribuzione normale perfetta, ma tendono a raggrupparsi verso la fascia bassa e media, con una coda lunga verso i punteggi alti che indicano la dipendenza. In un campione di studenti universitari malesi, il punteggio medio totale alla BSMAS è risultato essere 16.80 ($SD = 5.40$) su un massimo di 30 [34]. Questo valore medio colloca la popolazione studentesca in una zona di "rischio moderato" o uso intensivo, ma non necessariamente patologico. Tuttavia, la deviazione standard indica che una quota rilevante del campione ottiene punteggi superiori a 22-24, entrando nella fascia di rilevanza clinica. La prevalenza stimata della dipendenza varia enormemente in base al cut-off adottato.

I punteggi di dipendenza non sono uniformi a livello globale. Studi comparativi mostrano differenze significative tra culture individualiste e collettiviste [2]. In Italia, gli studenti mostrano livelli particolarmente elevati di *"Fear of Missing*

Out” (*FOMO*) e di dipendenza da internet in generale, ma punteggi di dipendenza dai social media (SMA) che possono essere inferiori rispetto ai coetanei di altri paesi europei o sudamericani [24], pur mantenendo alti livelli di *phubbing* (ignorare gli altri per guardare il telefono) [6]. In contesti collettivisti (come in Cina, Malesia e Indonesia), dove la connessione sociale è un imperativo culturale, i punteggi possono essere influenzati dalla pressione normativa a essere sempre reperibili [20, 21]. Tuttavia, la forte coesione familiare in paesi come l’Indonesia può fungere da fattore protettivo, moderando l’impatto negativo dello stress pandemico sull’uso dei social [26].

1.4 Variabili intervenienti nel fenomeno e influenza dei contesti sociodemografici

La correlazione tra punteggi di salute mentale scarsi e alti punteggi di dipendenza dai social media è robusta e ben documentata [1, 22, 35]; tuttavia, la ricerca psicologica ha indagato le variabili intervenienti (mediatori e moderatori) che potrebbero spiegare il fenomeno.

La FOMO emerge come il predittore più potente nella relazione tra disagio psicologico e SMA. Questa è una forma d’ansia sociale caratterizzata dal timore pervasivo che gli altri stiano vivendo esperienze gratificanti in propria assenza [25]. Analisi di *Structural Equation Modeling (SEM)* confermano che la FOMO media la relazione tra psicopatologia e uso problematico dei social media [9]. Individui con bisogni psicologici insoddisfatti (es. bisogno di appartenenza) sviluppano la FOMO, che a sua volta guida comportamenti di controllo compulsivo delle notifiche, risultando in punteggi SMA più elevati [7].

Un altro mediatore della relazione tra dipendenza dai social e salute mentale è il confronto sociale. L’esposizione costante a rappresentazioni idealizzate e curate della vita altrui innesca confronti verso l’alto, provocando sentimenti di invidia, inadeguatezza e, conseguentemente, portando a punteggi più alti di depressione [32]. A questa evidenza si associano quelle riferite alle modalità di utilizzo dei social. Un uso passivo (*scrolling*), senza interazione diretta, è costantemente associato a un aumento del malessere, probabilmente per via della mancanza di feedback sociali positivi e all’aumento delle opportunità di confronto sociale [3]. Un uso attivo, come messaggiare o commentare, mostra invece risultati ambivalenti; da un lato sembra favorire la connessione sociale, che è un fattore protettivo per i punteggi di salute mentale, mentre dall’altro la ricerca di validazione esterna può generare ansia da prestazione.

Oltre alle dimensioni psicologiche, un mediatore biologico cruciale si è visto essere il sonno [33]. L’uso serale dei social media ritarda l’addormentamento e provoca attivazione cognitiva/fisiologica (*arousal*) che peggiora la qualità del sonno [19]. La privazione di sonno riduce la capacità di regolazione emotiva, aumentando la suscettibilità a ansia e depressione il giorno successivo, che a loro volta possono portare a un maggior uso di social media come coping maladattivo [28].

Anche i fattori sociodemografici sembrano essere rilevanti nella relazione tra dipendenza e salute mentale.

Si è visto come le studentesse (16-25 anni) mostrino sistematicamente indicatori peggiori rispetto ai ragazzi in quasi tutte le metriche considerate [30]. Per quanto riguarda la salute mentale, la prevalenza di sintomatologia ansiosa moderata/grave può raggiungere il 41% nelle ragazze e il 15% nei ragazzi. Le donne, inoltre, ottengono punteggi BSMAS più elevati [23]. Questo potrebbe essere attribuito a diversi fattori: una maggiore tendenza relazionale che si traduce in un uso più intenso delle piattaforme comunicative, una maggiore sensibilità al feedback sociale e una pressione socioculturale più forte sull'immagine corporea, che i social media amplificano.

Si è rilevata anche un'influenza dello status socioeconomico. Per quanto riguarda la salute mentale, studenti provenienti da contesti a basso reddito mostrano tassi più elevati di depressione e ansia [27]. Per quanto riguarda l'uso dei social media, l'uso problematico può essere più frequente in contesti svantaggiati a causa della mancanza di alternative ricreative offline e di una minore educazione digitale in famiglia. A queste evidenze si aggiungono quelle sulla localizzazione geografica come determinante del benessere psicologico. Gli studenti delle aree rurali mostrano spesso livelli più elevati di sintomi depressivi, stress e rischio suicidario rispetto ai pari urbani [10]. Fattori contribuenti includono l'isolamento geografico, la minore accessibilità ai servizi di salute mentale, lo stigma sociale più marcato nelle piccole comunità e le minori opportunità economiche/educative. In questo contesto, i social media possono rappresentare un'ancora di salvezza per la connessione, ma anche un veicolo di confronto doloroso con stili di vita urbani irraggiungibili. Tuttavia, gli studenti urbani affrontano stressor specifici come l'alta densità abitativa, la competizione accademica e sociale, e il costo della vita.

Si evidenzia, infine, come la coesione familiare e uno stile genitoriale supportivo sono fattori protettivi robusti contro la dipendenza dai social media [26]. Al contrario, conflitti familiari, mancanza di supporto emotivo e scarsa supervisione sono predittori significativi dell'uso problematico dei social media, spesso utilizzato come meccanismo di fuga da un ambiente domestico stressante [29].

2 Metodologia

Per le analisi che verranno effettuate in questa ricerca sono stati utilizzati diversi modelli statistici.

Per prima cosa, si è impostato un modello di regressione lineare multiplo. Si è poi proceduto ad effettuare una selezione di variabili, utilizzando sia il metodo del Sequential Replacement che l'algoritmo Boruta, valutando la presenza di variabili rindondanti e come queste modificassero i criteri di valutazione AIC e BIC. Successivamente, si è impostato un ulteriore modello di regressione lineare sulla base delle conclusioni della selezione di variabili, e si è proseguito con l'analisi dei residui per valutarne le prestazioni. Infine, sulla base dei risultati ottenuti, si è ritenuto opportuno impostare un modello lineare generalizzato.

Di seguito, verranno descritti i principi matematici dei modelli utilizzati e il loro funzionamento.

2.1 Modello di regressione lineare

Per il modello di regressione lineare si ipotizza l'esistenza di una relazione tra una variabile target (o dipendente, Y) e delle variabili indipendenti (X). Nel caso più semplice, una sola X è sufficiente a spiegare la Y , e si parla di Regressione Lineare Semplice, dove la relazione tra le variabili è:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i \quad (1)$$

dove:

- y_i è l' i -esima osservazione della variabile dipendente;
- x_i è l' i -esima osservazione della variabile indipendente;
- β_0 è l'intercetta, ovvero il valore atteso di Y quando $X = 0$;
- β_1 è il coefficiente angolare, che informa su come varia il valore atteso di Y per una variazione unitaria di X ;
- ϵ_i è l'errore, ovvero tutto ciò che influenza Y ma non è X , quindi errori di misurazione, altre variabili, casualità intrinseca.

L'obiettivo del modello di regressione lineare è quello di stimare i coefficienti e l'intercetta.

Difficilmente un fenomeno può essere esaustivamente spiegato con una sola variabile indipendente. Si utilizzano quindi modelli di Regressione Lineare Multipla, la cui equazione diventa:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_j x_{ij} + \epsilon_i \quad (2)$$

dove ogni β_j rappresenta l'effetto di quella specifica variabile sulla variabile target.

Per individuare i coefficienti, si cercano i valori che minimizzano la Somma dei Quadrati dei Residui (SSE), ovvero:

$$SSE(\hat{\beta}_0, \dots, \hat{\beta}_k) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_j x_{ij}))^2 \quad (3)$$

Nel caso della Regressione Semplice, questo sistema di equazioni ci porta a due formule:

1. La Pendenza ($\hat{\beta}_1$):

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{Cov(X, Y)}{Var(X)} \quad (4)$$

per cui il coefficiente è dato dalla covarianza tra X e Y divisa per la varianza di X ;

2. L'intercetta ($\hat{\beta}_0$):

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (5)$$

per cui la retta passa sempre per il punto medio delle osservazioni $(\bar{x}, \bar{y})$.

Nel caso del modello Multiplo, si deve risolvere un sistema di $k + 1$ equazioni lineari per trovare i valori dei coefficienti.

Queste equazioni si basano sulle assunzioni di Gauss-Markov, ovvero:

1. Linearità nei parametri: il modello deve essere lineare nei coefficienti β ;
2. Campione Casuale: i dati devono essere estratti casualmente dalla popolazione;
3. Assenza di multicollinearità: nessuna variabile indipendente deve poter essere calcolata come combinazione esatta delle altre;
4. L'errore medio per ogni valore di X deve essere pari a zero. Non devono esserci pattern nascosti nell'errore legati alla X ;
5. Omoschedasticità: la varianza dell'errore attorno alla retta deve essere costante.

Il modello di regressione lineare è adatto per variabili target continue, ed è utile sia a scopo descrittivo che predittivo.

2.2 *Sequential Replacement*

Il *Sequential Replacement (SEQREP)* è un algoritmo di ottimizzazione combinatoria applicato all'algebra lineare.

L'obiettivo è quello di trovare un gruppo preciso di k variabili tra tutte le p variabili disponibili, in modo che l'errore complessivo del modello sia più piccolo possibile. In questo caso, quindi, si vuole minimizzare la Somma dei Quadrati dei Residui (RSS), ovvero:

$$RSS = \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad (6)$$

Non è possibile però calcolare l'RSS per tutte le possibili combinazioni di variabili. Metodi come la Forward Selection in questo caso falliscono poiché assumono che la variabile che è risultata la miglior scelta in precedenza rimanga necessaria nel momento in cui si selezionano le altre.

L'algoritmo SEQREP, invece, lavora con due gruppi di variabili: un gruppo attivo, ovvero le k variabili che sono state inserite nel modello, e un gruppo passivo, ovvero le variabili non ancora prese in considerazione. L'operazione fondamentale è lo Scambio, ovvero sostituire una variabile interna con una esterna solo se questo riduce l'RSS.

Il SEQREP usa una tecnica di calcolo incrementale. L'algoritmo usa delle formule di aggiornamento (formule di *updating* e *downdating*) che aggiustano i

calcoli esistenti. L'algoritmo inizia con un gruppo di k variabili; successivamente prende ogni variabile presente nel modello e la confronta con ogni variabile fuori dal modello. L'algoritmo cerca la coppia che garantisce il miglioramento massimo dell'RSS: se trova una coppia che abbassa l'errore, esegue lo scambio; se nessuno scambio possibile migliora l'errore, l'algoritmo si ferma. Se lo scambio avviene, si itera il processo sul nuovo gruppo di variabili attive finché non ci sono più miglioramenti possibili.

In sintesi, il SEQREP è un algoritmo di ricerca locale nello spazio dei modelli possibili. Sfrutta la matematica degli "aggiornamenti incrementali" della varianza per valutare rapidamente se la sostituzione di un predittore all'interno del gruppo attivo migliora la capacità predittiva globale, superando così la rigidità degli algoritmi che procedono solo aggiungendo (Forward) o solo togliendo (Backward) variabili.

2.3 Boruta

Boruta è un algoritmo di Machine Learning non parametrico che lavora con le Random Forest. A differenza del SEQREP che cerca il miglior sottoinsieme minimo (Minimal Optimal), Boruta cerca tutte le variabili rilevanti (All Relevant). Nell'addestrare un modello Random Forest, si ottiene per ogni variabile un punteggio di "Importanza", spesso basato su quanto quella variabile riduce l'impurità o l'errore. Boruta a questo aggiunge un riferimento esterno randomizzato, ovvero delle variabili fantasma con cui confrontare i punteggi di importanza delle variabili originali.

Per ogni variabile del dataset, Boruta crea una copia (Shadow Features) in cui i valori vengono mescolati casualmente tra le righe. Questo permette di eliminare qualsiasi eventuale correlazione tra la variabile target e le variabili indipendenti, mantenendo però inalterata le distribuzioni marginali delle variabili originali. L'algoritmo si basa sull'ipotesi secondo cui, se una variabile reale è importante, allora deve avere un'importanza predittiva superiore alla migliore delle variabili ombra.

Il primo passaggio dell'algoritmo è quello della duplicazione e del mescolamento delle p variabili reali. Successivamente, esegue un modello random forest su tutto il dataset esteso (comprensivo quindi sia di variabili ombra che di variabili reali) per cercare di predire la variabile target; questo modello assegna un punteggio di importanza a tutte le variabili. Si prendono poi in considerazione solo le variabili ombra, trovando quella che ha avuto il punteggio più alto (Max Z-Score Shadow), e si eseguono i confronti con le variabili: se una variabile reale ha un punteggio più alto del MZS, si segna un Punto, altrimenti no. Questo processo viene iterato molte volte, rigenerando ogni volta variabili ombra mescolate diversamente.

Dopo N iterazioni, si contano i Punti e si classificano le variabili:

- Variabile Confermata (Verde): indica che la variabile reale ha ottenuto un punteggio più alto dell'ombra un numero di volte statisticamente significativo, quindi la variabile è importante.

- Variabile Respinta (Rossa): indica che la variabile reale ha ottenuto troppe poche volte un punteggio più alto dell'ombra, quindi non è possibile distinguere il suo contributo dal rumore.
- Variabile Tentata (Blu): indica che non è stata riscontrata abbastanza evidenza statistica per decidere. Si potrebbe risolvere aumentando il numero di iterazioni.

2.4 Analisi dei Residui

I residui (e_i) sono la differenza tra il dato reale misurato e la stima calcolata dal modello.

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \quad (7)$$

Il metodo dei Minimi Quadrati impone due proprietà ai residui:

1. La loro somma deve essere uguale a zero
2. La covarianza tra residui e regressori deve essere zero

La varianza dell' i -esimo residuo dipende dal valore di Leva di quell'osservazione, ovvero:

$$Var(e_i) = \sigma^2(1 - h_{ii}) \quad (8)$$

Dove h_{ii} misura quanto l'osservazione x_i è distante dalla media $\bar{x}$. Più un punto è lontano dal centro dei dati (alta leva), più la retta tende a passare vicino a quel punto e il residuo sarà piccolo. Per rendere confrontabili punti con leve diverse si prendono in considerazione i residui standardizzati.

L'analisi dei residui si compone di una parte di diagnostica visiva, attraverso quattro grafici:

1. Residuals vs Fitted: sull'asse delle X si trovano i valori predetti ($\hat{y}$), sull'asse delle Y i residui (e). L'ideale sarebbe ottenere una nuvola di punti distribuita casualmente intorno allo zero. Se si nota una forma a parabola, l'utilizzo di un modello lineare è sbagliato poiché i dati potrebbero avere una relazione complessa; se si nota una forma ad imbuto, invece, è sintomo di eteroschedasticità, ovvero l'errore aumenta al crescere del valore predetto.
2. Normal Q-Q Plot: sull'asse delle Y ci sono i quantili dei residui, sull'asse delle X ci sono i quantili teorici di una distribuzione Normale. I punti dovrebbero trovarsi sulla linea tratteggiata nel grafico. Se formano una S, significa che ci sono molti valori estremi che potrebbero falsare i valori della t-statistic e i p-value; se formano una curva a banana, invece, i residui sono asimmetrici.
3. Scale-Location: sull'asse delle Y si trova la radice quadrata dei residui standardizzati in valore assoluto. Questo grafico rende più facile rilevare l'eteroschedasticità. Se la linea rossa di tendenza risulta orizzontale, la varianza è costante; se sale, la varianza dell'errore sta aumentando.

4. Residuals vs Leverage: sull'asse delle X c'è la Leva, sull'asse delle Y c'è il Residuo standardizzato. Un punto che ha alta Leva e alto Residuo potrebbe indicare un punto che piega la retta verso di sé e che se venisse eliminato farebbe cambiare drasticamente i coefficienti del modello.

A questa parte di diagnostica visiva si affiancano i test statistici formali per valutare la Normalità, l'omoschedasticità, l'autocorrelazione e la Distanza di Cook.

Il test di Normalità è quello di Shapiro-Wilk. Si testa l'ipotesi nulla secondo cui i residui sono distribuiti normalmente. Se il p-value è inferiore a 0.05, si rifiuta l'ipotesi nulla, quindi i residui non sono distribuiti normalmente.

Il test di omoschedasticità è quello di Breusch-Pagan. Si prendono i residui al quadrato e si cerca di prevederli usando le variabili X . Se le X riescono a predire l'errore al quadrato, significa che la varianza non è costante e dipende da X . L'ipotesi nulla, quindi, è quella secondo cui la varianza è costante; se si ottiene un p-value minore di 0.05, si è in presenza di eteroschedasticità, quindi si rifiuta l'ipotesi nulla e la varianza non è costante.

Il test di autocorrelazione è quello di Durbin-Watson, ed è fondamentale nelle serie storiche. Si verifica se l'errore di "oggi" dipende dall'errore di "ieri". Il test produce una statistica d che va da 0 a 4. Una d vicina a 2 indica nessuna correlazione, mentre una d minore di 1.5 indica correlazione positiva e una d maggiore di 2.5 indica correlazione negativa.

La Distanza di Cook aggrega in un unico numero la variazione totale di tutte le previsioni del modello nel caso un punto venisse rimosso.

$$D_i = \frac{e_i^2}{p * MSE} * \left(\frac{h_{ii}}{(1 - h_{ii})^2} \right) \quad (9)$$

D_i è il prodotto della Componente Residuo ($\frac{e_i^2}{p * MSE}$), che misura quanto il punto rappresenta un outlier sull'asse delle Y, e della Componente Leva ($\frac{h_{ii}}{(1 - h_{ii})^2}$), che misura quanto il punto rappresenta un outlier sull'asse delle X. Per avere una Distanza di Cook alta, un punto deve avere sia un residuo significativo che una leva alta.

Nel grafico Residuals vs Leverage sono tratteggiate le curve di isolivello della Distanza di Cook. I punti che si trovano nell'angolo in basso a sinistra sono punti con bassa leva e basso errore, i punti che si trovano in alto a destra o in basso a destra sono punti da indagare.

2.5 Modello Lineare Generalizzato

La regressione lineare è un caso particolare del Modello Lineare Generalizzato (GLM). Un GLM si compone di:

1. Componente Casuale: assume che la variabile dipendente Y segua una distribuzione che appartiene alla Famiglia Esponenziale (che include distribuzione Normale, Binomiale, Poisson, Gamma).

2. Componente Sistemática: si costruisce una combinazione lineare dei regressori X , ovvero:

$$\eta_i = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p \quad (10)$$

in cui η può assumere qualsiasi valore da $-\infty$ a $+\infty$.

3. Funzione Legame: si vuole collegare il valore atteso della variabile target con il predittore lineare η . Si usa una funzione tale che $g(\mu_i) = \eta_i$ o, inversamente, $\mu_i = g^{-1}(\eta_i)$.

Il modello, quindi, non prevede direttamente la Y , ma prevede una trasformazione della sua media.

Nel GLM non si usa la stima dei Minimi Quadrati, ma si utilizza la Stima di Massima Verosimiglianza (MLE), calcolata attraverso l'algoritmo IRLS che risolve iterativamente una serie di regressioni pesate; l'algoritmo si ferma quando la differenza tra i β del passo corrente e quelli del passo precedente è quasi zero.

La misura dell'errore nel GLM è la Devianza. Più è bassa, più il modello è vicino alla perfezione.

3 Analisi

Dati i riferimenti teorici e spiegato il fenomeno di interesse, di seguito si procederà a descrivere la ricerca e le analisi effettuate.

3.1 Descrizione del Dataset

La presente ricerca si basa sul dataset “Student Social Media & Relationships”, ottenuto da Kaggle. Si tratta di una raccolta di dati cross-sectional ottenuta tramite un sondaggio online somministrato nel primo trimestre del 2025. Il dataset offre una prospettiva globale, includendo risposte di studenti provenienti da diversi contesti geografici (tra cui USA, Brasile, Germania, India e Corea del Sud) e diversi livelli accademici (Scuola Superiore, Laurea Triennale/Magistrale e Dottorato).

Il dataset è composto da 705 osservazioni e le seguenti variabili:

- **Student_ID**: Un identificativo intero univoco assegnato a ciascun intervistato per consentire la deduplicazione e tracciare i singoli record senza rivelare informazioni personali.
- **Age**: Età dello studente in anni compiuti al momento dell'indagine.
- **Gender**: Il genere auto-dichiarato dallo studente, registrato come “Maschio” o “Femmina”.
- **Academic_Level**: Il livello di istruzione più alto a cui è attualmente iscritto l'intervistato, con le categorie: “Scuola superiore”, “Laurea triennale” o “Laurea magistrale”.

- **Country:** Il paese di residenza in cui lo studente ha completato l'indagine.
- **Avg_Daily_Usage_Hours:** Il numero medio di ore al giorno che lo studente trascorre sulle piattaforme dei social media, calcolato in base alle stime di utilizzo auto-dichiarate nei giorni feriali e nei fine settimana.
- **Most_Used_Platform:** La piattaforma di social media su cui lo studente trascorre più tempo, include Facebook, Instagram, KakaoTalk, LINE, LinkedIn, Snapchat, TikTok, Twitter, VKontakte, WeChat, Whatsapp e Youtube.
- **Affects_Academic_Performance:** Un indicatore binario ("Sì"/"No") che indica se lo studente percepisce l'utilizzo dei social media come un impatto negativo sul proprio rendimento scolastico.
- **Sleep_Hours_Per_Night:** Durata media del sonno notturno dell'intervistato in ore, fornita per indagare le correlazioni tra tempo trascorso davanti allo schermo e qualità/quantità del sonno.
- **Mental_Health_Score:** Un numero intero autovalutato da 1 (scarso) a 10 (eccellente) che indica il benessere mentale generale, consentendo di valutare potenziali associazioni con le abitudini sui social media.
- **Relationship_Status:** L'attuale stato sentimentale dello studente, classificato come "Single", "In Relazione" o "Complicato".
- **Conflicts_Over_Social_Media:** Il numero di discussioni o disaccordi che lo studente dichiara di aver avuto con familiari, amici o partner a causa dell'uso dei social media, funge da indicatore dell'attrito sociale.
- **Addicted_Score:** Un punteggio composito da 1 (bassa dipendenza) a 10 (alta dipendenza) basato su una scala di indagine standardizzata (ad esempio, la Bergen Social Media Addiction Scale), che quantifica il grado di utilizzo problematico.

3.2 Obiettivi della Ricerca

L'obiettivo centrale di questo lavoro è duplice:

1. Identificare i predittori critici che influenzano il benessere mentale degli studenti (**Mental_Health_Score**);
2. Analizzare i meccanismi che portano all'insorgenza della dipendenza digitale (**Addicted_Score**).

3.3 Analisi esplorativa del dataset

L'analisi esplorativa evidenzia che l'età media del campione è di 21 anni circa, con un range che va dai 18 anni ai 24 anni. La deviazione standard pari a 1.40 indica un campione omogeneo.

La media delle ore di utilizzo giornaliero indica che gli studenti passano circa 5 ore al giorno sui social media. Il valore massimo di 8.5 ore al giorno è rilevante poiché evidenzia casi di utilizzo estremo. Inoltre, la media delle ore di sonno a notte è pari a 6.87 ($sd = 1.13$), indicando che gli studenti dormono meno delle otto ore di sonno consigliate, rendendo interessante un'analisi per esplorare l'influenza che le ore di utilizzo dei social hanno sulle ore di sonno.

La media per gli score è di 6.23 ($sd = 1.11$) per il punteggio di salute mentale e di 6.44 ($sd = 1.59$) per il punteggio di dipendenza. I valori di skew, rispettivamente di 0.05 e -0.30, indicano una distribuzione quasi perfettamente simmetrica per quanto riguarda il punteggio di salute mentale e una distribuzione leggermente asimmetrica a sinistra, con maggiore presenza di valori medio-alti, per quanto riguarda il punteggio di dipendenza.

Non sono presenti valori mancanti.

Poiché il dataset presenta diverse variabili categoriali, è stato effettuato encoding. Si è scelto di eliminare le variabili non informative (Student_ID) e le variabili ad alta cardinalità (Country) perché la loro inclusione avrebbe reso il modello poco efficiente. Le variabili nominali come Gender, Most_Used_Platform, Affects_Academic_Performance e Relationship_Status sono state convertite in fattori, in modo che R sappia trattare correttamente le categorie durante la regressione. La variabile Academic_Level, in quanto variabile qualitativa ordinale, è stata trasformata in un fattore che tenga conto della gerarchia delle modalità.

Questo processo è essenziale per permettere le analisi successive. La regressione lineare, infatti, richiede che le categorie siano trasformate in valori numerici; i metodi di selezione delle variabili (Stepwise e Boruta), che pur gestiscono bene i fattori, beneficiano dell'encoding nella definizione delle categorie e delle feature informative.

Si è successivamente costruita una matrice di correlazione per osservare quali variabili presentano collinearità.




Figure 1: Matrice di Correlazione

Data la correlazione quasi totale tra dipendenza e salute mentale, mantenere entrambi i predittori porterebbe il modello a una saturazione informativa. Si è scelto di procedere eliminando le variabili ridondanti (come l'Addicted_Score nel modello che predice la salute mentale), focalizzando l'attenzione sui driver primari del fenomeno per evitare stime distorte o incoerenti.

L'esame della matrice di correlazione ha permesso di identificare tre nuclei tematici fondamentali che descrivono il comportamento e il benessere del campione analizzato.

Dall'analisi emerge un primo blocco di variabili caratterizzato da legami estremamente solidi, quasi sovrapponibili. Si osserva una correlazione positiva molto forte (con coefficienti compresi tra 0.80 e 0.95) tra le ore medie di utilizzo giornaliero (Avg_Daily_Usage_Hours), il punteggio di dipendenza (Addicted_Score) e la frequenza dei conflitti relazionali (Conflicts_Over_Social_Media).

Questa evidenza suggerisce che un uso intensivo dei social media non sia un fenomeno isolato, ma si accompagni inevitabilmente a una percezione di dipendenza e a un aumento delle tensioni interpersonali. Dal punto di vista statistico, valori così elevati (come il legame di $r = 0.95$ tra dipendenza e conflitti) segnalano un rischio di collinearità. Inserire tutte queste variabili contemporaneamente nel modello renderebbe le informazioni ridondanti e i risultati instabili.

Il punteggio di salute mentale (Mental_Health_Score) rappresenta il fulcro dell'indagine e mostra relazioni opposte ma altrettanto significative:

- **Relazione Inversa con la Dipendenza:** La correlazione negativa rasenta la perfezione ($r = 0.95$) con l'Addicted_Score. Questo dato indica che all'aggravarsi della dipendenza corrisponde un declino drastico del be-

nessere psicologico.

- Relazione Diretta con il Sonno: Specularmente, si osserva un legame positivo solido ($r = 0.73$) con le ore di sonno notturne (Sleep_Hours_Per_Night), confermando il riposo come uno dei principali fattori protettivi per l'equilibrio mentale degli studenti.

Al centro della matrice, le relazioni appaiono più sfumate. Come prevedibile, esiste una forte associazione tra età e livello accademico ($r = 0.86$), segno di una progressione coerente nel percorso di studi. Al contrario, variabili come il genere e lo stato sentimentale mostrano correlazioni vicine allo zero con quasi tutti gli altri indicatori. Questo suggerisce che, nel campione in esame, il malessere digitale e le abitudini d'uso siano trasversali e non dipendano in modo lineare dall'appartenenza di genere o dalla situazione sentimentale del singolo studente.

3.4 Analisi del Punteggio di Salute Mentale

In questa parte dell'analisi cercheremo di identificare i predittori critici che influenzano il benessere mentale degli studenti. Ai fini di una migliore interpretazione dei risultati si è scelto di standardizzare solo le variabili indipendenti e mantenere immutata la variabile dipendente (Mental_Health_Score).

3.4.1 Modello di Regressione Lineare Multipla

È stato implementato un modello di regressione lineare multipla per valutare la capacità predittiva delle variabili indipendenti. Al fine di garantire la stabilità dei coefficienti e prevenire fenomeni di multicollinearità, sono state escluse le variabili che presentavano una correlazione eccessiva con il target (Addicted_Score, Conflicts_Over_Social_Media, Affects_Academic_Performance), evitando così distorsioni nelle stime degli altri predittori.

Il modello ha mostrato un'ottima capacità predittiva, con un R^2 del 71.7%. Dall'interpretazione dei coefficienti emerge un quadro chiaro:

- Il tempo trascorso online è il predittore più forte e negativo ($\beta \approx -0.76$). Nello specifico, le piattaforme di intrattenimento visivo (TikTok, Instagram) risultano avere un impatto negativo, a differenza di quelle di messaggistica (Whatsapp) che mostrano un impatto positivo.
- Il sonno influisce positivamente sulla salute mentale, sebbene il suo effetto non riesca a compensare completamente l'impatto dell'uso intensivo.

La robustezza di questi risultati è stata poi verificata attraverso tecniche di selezione delle variabili (Sequential Replacement e Boruta). Entrambi i metodi hanno confermato la significatività statistica dei predittori scelti, evidenziando in particolare la centralità delle variabili Avg_Daily_Usage_Hours e Sleep_Hours_Per_Night. I criteri informativi (AIC e BIC) hanno inoltre dimostrato che il modello attuale mantiene un ottimo equilibrio tra complessità e capacità predittiva.

Nonostante l'elevata varianza spiegata, i test diagnostici hanno rivelato i limiti strutturali dell'approccio lineare per questi dati:

- Normalità: Il test di Shapiro-Wilk ha mostrato una lieve deviazione dalla normalità dei residui.
- Eteroschedasticità: Il test di Breusch-Pagan ($p < 0.001$) ha evidenziato una varianza degli errori non costante.
- Natura dei dati: La variabile dipendente è un punteggio discreto e limitato, mal si adatta alle assunzioni della regressione lineare classica.

Alla luce di queste violazioni delle assunzioni di base, si ritiene necessario abbandonare il modello lineare in favore di un Modello Lineare Generalizzato (GLM) della famiglia Quasi-Poisson. Tale approccio è statisticamente più appropriato poiché gestisce correttamente la natura discreta dei dati e la dispersione della varianza rilevata.

3.4.2 Modello Lineare Generalizzato

La regressione lineare multipla assume che la variabile target sia continua e distribuita normalmente, con un range che può spaziare da meno a più infinito. Al contrario, i punteggi del nostro dataset sono valori discreti limitati (con range 1-10) e non negativi, si tratta quindi di dati di conteggio.

Per rispettare questi vincoli strutturali, si è quindi optato per la distribuzione di Poisson. Questa scelta garantisce che le previsioni del modello siano confinate entro valori strettamente positivi, rispecchiando la natura della variabile target.

Tuttavia, l'applicazione di un modello di Poisson standard richiede il presupposto di "equidispersione", ovvero l'uguaglianza tra media e varianza ($E(Y) = Var(Y)$). Un'analisi preliminare ha rivelato una violazione di questo assunto, evidenziando una marcata sottodispersione: il parametro di dispersione calcolato (0.088) indica che la varianza effettiva dei punteggi è sensibilmente inferiore alla loro media. Utilizzare una Poisson classica in questo contesto avrebbe prodotto errori standard distorti e p-value non attendibili. Per correggere tale distorsione, si è scelto di adottare il modello Quasi-Poisson, che svincola il calcolo dal rigido presupposto di equidispersione, adattando le stime alla variabilità reale del campione per ottenere risultati statisticamente robusti.

A completamento della struttura del modello, è stata integrata una funzione di collegamento logaritmica. Questa funzione ci ha permesso di evitare punteggi negativi e di interpretare i risultati in termini moltiplicativi. Invece di limitarci a osservare variazioni puntuali, questa funzione consente di quantificare l'impatto dei predittori in termini di variazioni percentuali.

Per la costruzione del modello lineare generalizzato le variabili indipendenti verranno standardizzate e verranno escluse le variabili con elevata correlazione. Da un'analisi preliminare le variabili Age e Relationship_Status sono risultate non significative, di conseguenza sono state scartate. I risultati ottenuti sono:

- Intercetta ($\beta_0 = 1.842$): rappresenta il valore atteso del logaritmo del punteggio di salute mentale quando tutte le variabili numeriche sono a zero e tutte le variabili categoriche sono al loro livello di riferimento. Il valore predetto del punteggio è $e^{1.842} \approx 6.31$.

- La variabile GenderMale ($\beta = 0.024$; $e^{0.024} \approx 0.976$) mostra come gli studenti abbiano una riduzione del 2.4% del punteggio di salute mentale rispetto alle femmine, a parità di ogni altra variabile. L'effetto è piccolo ma statisticamente significativo.
- La variabile Avg_Daily_Usage_Hours ($\beta = 0.127$; $e^{0.127} \approx 0.881$) si dimostra essere il predittore più critico. Per ogni ora extra passata sui social, il punteggio di salute mentale diminuisce del 11.9%. È un effetto cumulativo: due ore extra riducono il punteggio del 22.4% (0.881^2).
- La variabile Sleep_Hours_Per_Night ($\beta = 0.021$; $e^{0.021} \approx 1.021$) presenta un effetto protettivo sulla salute mentale: ogni ora di sonno in più aumenta il punteggio del 2.1%.
- Per la variabile Academic_Level possiamo osservare sia il trend lineare sia il trend quadratico:
 1. Academic_Level.L (Trend Lineare) $\beta = 0.050$; $e^{0.050} \approx 1.051$: Esiste una relazione di proporzionalità diretta significativa. In generale, man mano che si sale nella scala dell'istruzione, il punteggio di salute mentale tende a salire. Ogni "gradino" accademico moltiplica il benessere per circa 1.05.
 2. Academic_Level.Q (Trend Quadratico) $\beta = 0.034$; $e^{-0.034} \approx 0.967$: Questo valore indica la "curvatura" della relazione. Essendo negativo, siamo di fronte a una parabola con la concavità rivolta verso il basso.

In base ai risultati ottenuti possiamo dividere la variabile Most_Used_Platform in 3 categorie, differenziate dall'effetto sul punteggio di salute mentale:

1. Piattaforme con effetto negativo: KakaoTalk ($\beta = 0.101$) e Snapchat ($\beta = 0.085$) hanno l'effetto peggiore. Usare KakaoTalk riduce il punteggio del 9.7% ($e^{-0.101} \approx 0.93$), mentre Snapchat dell'8.2% ($e^{-0.085} \approx 0.918$). Spesso queste app sono legate a una comunicazione istantanea e continua che può generare ansia da prestazione o dipendenza. TikTok ($\beta = 0.064$) e Instagram ($\beta = 0.062$): entrambe riducono il benessere di circa il 6% (rispettivamente $e^{-0.064} \approx 0.937$ e $e^{-0.062} \approx 0.939$). È interessante notare come siano quasi identiche: entrambe si basano su contenuti visivi altamente rifiniti (algoritmi di scroll infinito) che favoriscono il confronto sociale verso l'alto.
2. Piattaforme con effetto positivo: X, precedentemente Twitter, ($\beta = 0.052$) è associato a un aumento del 5.4% ($e^{0.052} \approx 1.054$) del punteggio. Questo potrebbe essere dovuto al fatto che questa piattaforma è più orientata al testo, alla condivisione di contenuti artistici e all'informazione. WhatsApp ($\beta = 0.039$) aumenta il punteggio del 4% ($e^{0.039} \approx 1.04$). Essendo uno strumento di messaggistica diretta, favorisce il mantenimento di relazioni reali e il supporto sociale, agendo come fattore protettivo invece che stressogeno.

3. Piattaforme non significative: per piattaforme come LinkedIn, YouTube, WeChat, LINE e VKontakte, i p-value sono superiori alla soglia di significatività ($p > 0.05$), ciò dimostra che non hanno effetti significativi sul campione analizzato.

Oltre alla stima dei singoli coefficienti, l'affidabilità del modello è stata valutata attraverso l'analisi dei parametri di diagnostica finale.

Il Parametro di Dispersione, utilizzato per verificare la relazione tra media e varianza e per convalidare la robustezza degli errori standard calcolati, in questo caso è 0.057. Ciò indica sottodispersione: i punteggi di salute mentale nel dataset sono molto “compatti” e vicini tra loro rispetto a quanto ci si aspetterebbe. Usando la famiglia quasipoisson, il modello ha rimpicciolito gli Standard Error, rendendo i tuoi p-value più affidabili.

Il modello presenta inoltre una Null deviance (ovvero l'errore del modello che usa solo l'intercetta per indovinare il punteggio) di 139.286 on 704 DF, e una Residual deviance (ovvero l'errore che rimane dopo aver aggiunto i predittori) di 40.327 on 688 DF. Notiamo che l'errore viene ridotto del 71%. Questo indica che le variabili indipendenti sono eccellenti predittori della salute mentale.

Si è proseguito poi effettuando un'analisi dei residui.




Figure 2: Residuals vs Fitted

Il grafico Residuals vs Fitted controlla la linearità e l'omoschedasticità. I residui si dispongono in linee diagonali parallele, dovuto al fatto che la variabile dipendente è discreta (punteggio intero da 1 a 10). La linea rossa è quasi perfettamente orizzontale e vicina allo zero, ciò indica che la funzione di legame log ha catturato correttamente la struttura dei dati e non ci sono vistose mancanze di

linearità. Il test di Breusch-Pagan ha rilevato una significativa eteroschedasticità ($p < 0.001$), un risultato che convalida l'utilizzo della famiglia Quasi-poisson, la quale permette una stima robusta degli errori standard anche in presenza di varianza non costante. La diagnostica post-stima rivela un'assenza di autocorrelazione nei residui (Durbin-Watson = 2.26, $p \approx 1$), confermando l'indipendenza delle osservazioni.




Figure 3: Q-Q Plot

Il test di Shapiro-Wilk ha rilevato una deviazione significativa dalla normalità dei residui ($W=0.987$, $p < 0.001$). Tuttavia, considerando l'elevata numerosità campionaria e l'aderenza visiva osservata nel Q-Q Plot, tale scostamento è da considerarsi trascurabile. Inoltre, l'adozione di un modello Quasipoisson garantisce la robustezza delle stime anche in presenza di lievi non-normalità, poiché il modello si concentra sulla corretta modellazione della relazione media-varianza piuttosto che sulla normalità distributiva dei residui di devianza.




Figure 4: Scale-Location

Il grafico Scale-Location evidenzia una moderata eteroschedasticità, indicata dalla lieve pendenza negativa della linea rossa. Tale evidenza, supportata dai risultati del test di Breusch-Pagan, conferma la necessità di utilizzare un approccio di stima robusto. L'adozione del modello Quasi-poisson permette di gestire correttamente questa struttura della varianza, garantendo che i coefficienti stimati non siano distorti dalla dispersione non costante dei residui.




Figure 5: Residuals vs Leverage




Figure 6: Punti di leva




Figure 7: Distanza di Cook

Il grafico Residuals vs Leverage conferma l'assenza di osservazioni influenti che possano distorcere le stime del modello. Nessun punto supera, o si avvicina, alle soglie critiche della Distanza di Cook. Sebbene siano presenti alcuni casi con leverage moderatamente elevato, i loro residui contenuti indicano che tali osservazioni sono coerenti con la struttura globale del modello, garantendo la robustezza delle inferenze prodotte.

3.4.3 Considerazioni finali sul punteggio di salute mentale

Dall'analisi emerge un quadro estremamente nitido: la salute mentale degli studenti è il risultato di un delicato equilibrio tra abitudini di riposo e la scelta degli ambienti virtuali frequentati. Il modello lineare generalizzato è riuscito a spiegare oltre il 70% di questo fenomeno, un risultato che ci permette di parlare con discreta certezza.

Il dato più interessante è la netta distinzione tra le piattaforme. Non siamo di fronte a un effetto negativo generalizzato; piuttosto, assistiamo a una gerarchia del rischio. Social come TikTok, Instagram e Snapchat si confermano i principali predittori di un calo del benessere. Questo suggerisce che il formato del video breve e la cultura dell'immagine istantanea creino una sorta di "rumore di fondo" ansiogeno, probabilmente dovuto al confronto sociale costante e alla natura ipnotica degli algoritmi di raccomandazione.

Al contrario, l'uso di piattaforme più orientate alla comunicazione diretta o all'informazione, come WhatsApp e X (Twitter), sembra quasi innocuo o, in certi casi, funzionale. Questo ci dice che il social media, quando funge da puro strumento di connessione umana o di aggiornamento, non erode la salute mentale

nello stesso modo in cui lo fa un'app basata sulla performance estetica.

Se i social rappresentano la sfida, il sonno emerge come la difesa più potente a disposizione dello studente. I risultati mostrano che ogni ora di riposo notturno agisce come un fattore rigenerativo diretto. Il sonno sembra attenuare gli impatti negativi accumulati durante la giornata digitale.

3.5 Analisi del Punteggio di Dipendenza

In questa parte dell'analisi il focus verrà spostato su un'altra variabile target: il punteggio di dipendenza (`Addicted_Score`). L'obiettivo è individuare quali sono i fattori che portano alla dipendenza digitale negli studenti.

Come per l'analisi precedente, prepariamo il dataset: verranno rimosse le variabili non informative o ad alta cardinalità (`Student_ID` e `Country`), le variabili nominali (`Gender`, `Most_Used_Platform`, `Affects_Academic_Performance` e `Relationship_Status`) sono state convertite in fattori e la variabile `Academic_Level`, in quanto variabile qualitativa ordinale, è stata trasformata in un fattore che tenga conto della gerarchia delle modalità. Successivamente standardizziamo le variabili indipendenti numeriche e rimuoviamo le variabili ad alto rischio di collinearità, in questo caso `Conflicts_Over_Social_Media`, e `Mental_Health_Score` (si rimanda alla matrice di correlazione).

3.5.1 Modello Lineare Generalizzato

L'esperienza osservata con la variabile `Mental_Health_Score` ha evidenziato come i modelli lineari standard fallissero nel gestire la natura discreta e l'eteroschedasticità dei punteggi. Il modello Quasi-poisson si è dimostrato superiore, offrendo una riduzione della devianza più marcata e una diagnostica dei residui più pulita. Pertanto, tale approccio viene confermato anche per lo studio dell' `Addicted_Score`, data l'identica struttura statistica della variabile target.

Il modello impostato con tutte le variabili come predittori spiega circa il 90% della variabilità della dipendenza. Nonostante ciò, data la presenza di variabili non significative, si è deciso di effettuare una selezione di variabili prima di interpretare i risultati.




Figure 8: Selezione di variabili con Sequential Replacement

Dal grafico si osserva come il metodo Stepwise abbia proposto due modelli con valori di Adjusted R-squared ugualmente elevati ($R^2 = 0.91$). Entrambi condividono le variabili: ore di uso quotidiano; influenza sulle prestazioni scolastiche; uso di particolari piattaforme (KakaoTalk, LINE, Twitter e WhatsApp). I modelli differiscono per le variabili riferite al livello di studio, ore di sonno per notte e stato sentimentale. Entrambi scartano le variabili riferite agli aspetti demografici del campione (età e genere).




Figure 9: Selezione di variabili con Boruta

L'algoritmo Boruta conferma che tutte le variabili inserite sono predittori validi. I predittori più forti restano le ore di utilizzo e, soprattutto l'influenza sulle prestazioni scolastiche.

Unendo le considerazioni fatte con entrambi i metodi, si è impostato un modello di regressione lineare generalizzato con le variabili risultate rilevanti. I risultati del modello indicano:

- L'intercetta ($\beta_0 = 1.674$) rappresenta il valore atteso del logaritmo del punteggio di dipendenza quando tutte le variabili numeriche sono a zero e tutte le variabili categoriche sono al loro livello di riferimento. Il valore predetto del punteggio è $e^{1.674} \approx 5.33$
- Per la variabile Academic_Level (.L e .Q) il modello utilizza contrasti polinomiali. Il valore negativo della componente lineare ($\beta = 0.043$) suggerisce che, in generale, la dipendenza tende a scendere leggermente man mano che si avanza nei gradi accademici, ma la componente quadratica positiva ($\beta = 0.23$) indica che questa discesa non è costante e potrebbe subire inversioni o rallentamenti in fasi specifiche del percorso.
- Avg_Daily_Usage_Hours ($\beta = 0.093$): Essendo positivo e altamente significativo, indica che all'aumentare delle ore passate online, la dipendenza cresce. Matematicamente, ogni aumento di un'ora di utilizzo moltiplica il punteggio di dipendenza per $e^{0.093} \approx 1.10$. Chi usa molto i social ha una probabilità del 10% superiore di avere un punteggio di dipendenza più alto rispetto alla media.

- Sleep_Hours_Per_Night ($\beta = 0.020$): Il segno negativo indica un effetto protettivo per cui ogni aumento di un'unità nelle ore di sonno riduce il punteggio di dipendenza di circa il 2% ($e^{-0.020} \approx 0.98$).
- Affects_Academic_Performance ($\beta = 0.312$): Questo è il coefficiente più alto del modello. Indica che per gli studenti che percepiscono un calo nel rendimento, il punteggio di dipendenza è circa il 36% più alto ($e^{0.312} \approx 1.36$) rispetto a chi non avverte tale impatto. Questo suggerisce che la dipendenza “percepita” è strettamente legata al danno funzionale nello studio.

In base ai risultati ottenuti dividiamo la variabile Most_Used_Platform in 3 categorie, differenziate dall'effetto sul punteggio di dipendenza:

1. Piattaforme ad alto rischio: YouTube ($\beta = 0.078$) è l'unica piattaforma che mostra un incremento statisticamente significativo del punteggio di dipendenza. Il meccanismo dell'autoplay, unito a raccomandazioni algoritmiche estremamente precise, trasforma il consumo di video in un comportamento compulsivo difficile da interrompere a volte trasformandosi in una parte della routine dello studente.
2. Piattaforme professionali e di messaggistica: LINE ($\beta = 0.406$) e KakaoTalk ($\beta = 0.157$) sono le app che rappresentano gli effetti più forti. L'uso di LINE riduce il rischio di dipendenza di circa il 33% rispetto al riferimento. Queste app sono focalizzate sulla comunicazione interpersonale diretta: una volta terminata la conversazione, l'utente tende a chiudere l'app, a differenza dei social basati su “feed” infiniti. Lo stesso principio si applica per WhatsApp ($\beta = 0.090$), agendo come fattore di riduzione della dipendenza. Il suo scopo è funzionale e limita la ricerca di gratificazione dopaminergica tipico di altre piattaforme. Twitter ($\beta = 0.078$), nonostante la sua natura di feed in tempo reale, mostra un'associazione negativa con la dipendenza. Questo suggerisce che l'uso prevalente come fonte di notizie o micro-blogging non innesca i medesimi meccanismi di loop delle piattaforme puramente visuali. L'uso professionale di LinkedIn è inversamente proporzionale alla dipendenza compulsiva ($\beta = 0.131$). Essendo orientata alla carriera, il tempo speso su questa piattaforma è percepito come “produttivo” e meno soggetto a dinamiche di perdita di controllo tipiche dell'intrattenimento.
3. Piattaforme non significative: piattaforme come Instagram e TikTok, pur essendo centrali nel dibattito sulla dipendenza, non mostrano un coefficiente significativo poiché il loro contributo al rischio è già interamente mediato dal volume orario di utilizzo. Esse rappresentano la ‘linea di base’ della dipendenza digitale studentesca, rispetto alla quale solo piattaforme con architetture specifiche (come YouTube per eccesso e le app di messaggistica per difetto) riescono a deviare in modo statisticamente rilevante.

L'efficacia del modello è misurata dal confronto tra la Devianza Nulla (289.25) e la Devianza Residua (24.75). Il passaggio dal modello nullo a quello ottimizzato ha permesso di ridurre l'errore del 91% circa. Quindi le variabili selezionate riescono a spiegare la quasi totalità della variabilità del fenomeno della dipendenza nel campione studentesco esaminato, lasciando al caso o a variabili non misurate solo una minima parte della varianza residua.

Il parametro di dispersione (0.0358), sensibilmente inferiore all'unità, indica una marcata sottodispersione dei dati. Questo valore convalida definitivamente l'approccio Quasipoisson.




Figure 10: Residuals vs Fitted

Il grafico dei residui conferma la bontà del fit del modello. Nonostante la natura discreta della variabile dipendente generi la tipica struttura a bande parallele, la linea di regressione dei residui rimane costantemente prossima allo zero. Questo attesta l'assenza di distorsioni sistematiche e conferma che la funzione di legame logaritmica ha modellato correttamente le relazioni tra le variabili, garantendo l'affidabilità delle inferenze prodotte. La validità del modello è stata ulteriormente verificata tramite i test diagnostici sui residui. Il test di Breusch-Pagan ($p < 0.001$) ha confermato la presenza di eteroschedasticità nei dati, validando la scelta metodologica di utilizzare un modello Quasi-poisson. Parallelamente, il test di Durbin-Watson ($DW=2.15$; $p = 0.98$) ha escluso la presenza di autocorrelazione nei residui, confermando l'indipendenza delle osservazioni e, di conseguenza, la solidità delle stime dei coefficienti riportate.




Figure 11: Q-Q Plot

Il Q-Q Residuals plot conferma la validità del modello proposto. La quasi totalità dei residui si allinea con estrema precisione lungo la diagonale teorica, dimostrando che il modello cattura correttamente la struttura distributiva dei dati. Le lievi divergenze osservate nella coda superiore indicano la presenza di rari casi isolati con punteggi anomali rispetto ai predittori inseriti, ma la loro esiguità numerica non pregiudica la robustezza complessiva delle inferenze statistiche e la stabilità dei coefficienti calcolati. Il test di Shapiro-Wilk applicato ai residui ($W=0.99$; $p = 0.016$) indica una lieve deviazione dalla distribuzione normale. Tuttavia, tale risultato non pregiudica la validità dell'analisi, poiché i modelli Lineari Generalizzati (GLM) non poggiano sull'assunto di normalità dei residui. La vicinanza del parametro W all'unità e la precedente analisi del Q-Q Plot confermano che tale scostamento è imputabile esclusivamente a pochi casi isolati e alla natura discreta della scala di misura (1-10), confermando la robustezza complessiva delle stime ottenute.




Figure 12: Scale-Location

Il grafico Scale-Location conferma l'assunzione di omoschedasticità del modello. La linea rossa di tendenza si mantiene sostanzialmente orizzontale, indicando che la variabilità dei residui rimane costante lungo tutto il range dei valori predetti. La peculiare distribuzione a 'V' dei punti è riconducibile alla natura discreta della variabile dipendente (punteggio 1-10) e non indica anomalie nel fit. La stabilità del trend conferma che il parametro di dispersione del modello Quasi-poisson ha corretto efficacemente la struttura della varianza, garantendo stime coerenti.




Figure 13: Residuals vs Leverage




Figure 14: Punti di Leva




Figure 15: Distanza di Cook

Il grafico Residuals vs Leverage esclude la presenza di osservazioni influenti che possano aver distorto le stime del modello. Nonostante l'individuazione di alcuni outlier e di alcuni profili con leva moderata, nessuno di essi supera o si avvicina alle soglie critiche della Distanza di Cook. Ciò garantisce che i coefficienti calcolati per le variabili siano rappresentativi dell'intero campione e non condizionati da casi isolati o anomali, confermando la stabilità e la generalizzabilità dei risultati ottenuti.

3.5.2 Considerazioni finali sul punteggio di dipendenza

Dall'analisi dei punteggi di dipendenza emerge un quadro altrettanto nitido e coerente: la perdita di controllo digitale non è un evento casuale, ma il risultato diretto di come lo studente decide di abitare lo spazio virtuale. Il modello ottimizzato è riuscito a spiegare oltre il 91% di questo fenomeno, una precisione statistica eccezionale che ci permette di identificare con estrema chiarezza i motori del comportamento compulsivo.

Il dato più significativo è la conferma che la dipendenza non è solo una questione di tempo, ma di impatto reale sulla vita. Il modello evidenzia come il principale campanello d'allarme sia il conflitto con il rendimento accademico: la dipendenza si manifesta con forza quando lo studente percepisce che il digitale sta erodendo i suoi obiettivi concreti. Non è dunque il "troppo utilizzo" in sé a definire il problema, ma la sua capacità di interferire con i doveri e le ambizioni del quotidiano.

Proprio come per la salute mentale, assistiamo a una netta gerarchia del rischio tra le piattaforme. YouTube si staglia come l'ambiente più insidioso: la

sua architettura basata su flussi video continui e algoritmi di raccomandazione sembra creare un “loop” di consumo passivo difficile da interrompere. Al contrario, le app di messaggistica pura come WhatsApp, LINE e KakaoTalk agiscono quasi come fattori di protezione. Questo ci suggerisce che quando il social media rimane uno strumento di comunicazione diretta e finalizzata, il rischio di sviluppare un legame patologico crolla drasticamente rispetto ai social basati sull'intrattenimento infinito.

In questo scenario, il sonno si conferma ancora una volta la difesa più preziosa. I risultati mostrano che un buon riposo notturno non è solo un effetto collaterale di un minor uso dello smartphone, ma una risorsa attiva: ogni ora di sonno guadagnata agisce come un freno alla vulnerabilità digitale, fornendo allo studente le risorse cognitive necessarie per regolare i propri impulsi e mantenere un rapporto sano con la tecnologia.

4 Conclusioni

L'intera analisi delinea un panorama digitale in cui la salute mentale e la dipendenza degli studenti non sono conseguenze inevitabili della tecnologia, ma l'esito di un'interazione specifica tra l'architettura delle piattaforme e i ritmi biologici individuali. Il confronto tra i due modelli rivela una convergenza quasi totale, con un'unica, fondamentale differenza nel ruolo di alcune piattaforme.

In entrambi i fenomeni osservati, il sonno emerge come la variabile più stabile e protettiva. In un sistema complesso dove le app competono per l'attenzione, ogni ora di riposo notturno agisce contemporaneamente come un rigeneratore dell'umore e come un freno agli impulsi compulsivi. È la dimostrazione che la salute digitale non si costruisce solo “online”, ma soprattutto salvaguardando i bisogni primari “offline”.

L'aspetto più rivelatore emerge confrontando come le diverse piattaforme influenzano i due modelli. Sebbene l'impatto complessivo sia simile, le sfumature d'uso mostrano meccanismi psicologici differenti:

- Piattaforme di Dipendenza “Algoritmica” (YouTube): Mentre YouTube non è risultato il principale colpevole del calo di salute mentale, esso domina il modello della dipendenza. Questo suggerisce che il suo formato video lungo e il sistema di raccomandazioni creino un legame puramente compulsivo, che sequestra il tempo dello studente senza necessariamente generare, nell'immediato, lo stress sociale tipico di altri network.
- Piattaforme di “Confronto Sociale” (TikTok, Instagram, Snapchat): Questi social si sono confermati i principali driver del calo di salute mentale. Qui il problema non è solo il tempo speso, ma la natura del contenuto: l'esposizione costante a standard estetici elevati e la cultura dell'immagine istantanea creano un “rumore ansiogeno” che erode il benessere psicologico, indipendentemente dal fatto che l'utente si senta o meno tecnicamente “dipendente”.

- Piattaforme di Utilità (WhatsApp, LINE, Twitter/X): In entrambi i modelli, queste app occupano una posizione neutrale o addirittura positiva. La loro natura di strumenti per la comunicazione diretta o per l'aggiornamento informativo impedisce la creazione di quei “loop” ipnotici tipici delle piattaforme basate sullo scrolling infinito.

References

- [1] Andreassen, C. S., Billieux, J., Griffiths, M. D., et al. (2016). The relationship between addictive use of social media and video games and symptoms of psychiatric disorders: A large-scale cross-sectional study. *Psychology of Addictive Behaviors*, 30(2), 252–262.
- [2] Bányaí, F., Zsila, Á., Király, O., et al. (2017). Problematic social media use: Results from a large-scale nationwide survey. *PLOS ONE*, 12(1), e0169839.
- [3] Beyens, I., Pouwels, J. L., van Driel, I. I., Keijsers, L., & Valkenburg, P. M. (2020). The effect of social media use on adolescents’ well-being: A three-wave panel study. *Journal of Youth and Adolescence*, 49, 194–207.
- [4] Billieux, J. (2012). Problematic use of the mobile phone: A literature review and a pathways model. *Current Psychiatry Reviews*, 8(4), 299–307.
- [5] Billieux, J., Schimmenti, A., Khazaal, Y., Maurage, P., & Heeren, A. (2015). Are we overpathologizing everyday life? A tenable blueprint for behavioral addiction research. *Journal of Behavioral Addictions*, 4(3), 119–123.
- [6] Błachnio, A., Przepiórka, A., & Gorbaniuk, O. (2018). Phubbing, social media addiction, and relationship satisfaction in Italy. *Journal of Social and Personal Relationships*, 35(7), 1042–1059.
- [7] Casale, S., Rugai, L., & Fioravanti, G. (2018). Exploring the role of positive metacognitions in explaining the association between FOMO and social media addiction. *Addictive Behaviors*, 85, 83–87.
- [8] Casares, M. Á., Díez-Gómez, A., Pérez-Albéniz, A., Lucas-Molina, B., & Fonseca-Pedrero, E. (2024). Depressive and Anxious Symptoms in Spanish Adolescents: Normative Data for the PHQ-9 and GAD-7. *Clínica y Salud*, 35(2), 77–83.
- [9] Dadiotis, A., & Roussos, P. (2024). Relationship Between FoMO, Problematic Social Media Use, Self-esteem, Negative Affectivity, and Physical Exercise: A Structural Equation Model. *Journal of Technology in Behavioral Science*, 9, 313–324.
- [10] Fontanella, C. A., Hiance-Steelesmith, D. L., Phillips, G. S., et al. (2015). Widening rural–urban disparities in youth suicide. *Journal of the American Academy of Child & Adolescent Psychiatry*, 54, 110–117.

- [11] Griffiths, M. D. (2005). A ‘components’ model of addiction within a biopsychosocial framework. *Journal of Substance Use*, 10(4), 191–197.
- [12] Griffiths, M. D. (2017). Behavioural addiction and technology: Theoretical and clinical implications. *Journal of Behavioral Addictions*, 6(3), 271–273.
- [13] Healthy Minds Network. (2024). *The Healthy Minds Study: 2023–2024 Data Report*. University of Michigan School of Public Health.
- [14] Healthy Minds Network. (2025). *The Healthy Minds Study: 2024–2025 Data Report*. University of Michigan School of Public Health.
- [15] Inside Higher Ed. (2024). *College Students’ Mental Health Takes a Turn—For the Better*. Disponibile online.
- [16] Inside Higher Ed. (2024). *Key Mental Health Stats in Higher Education*. Report/Article.
- [17] Kaggle. (2025). *Student Social Media & Relationships Dataset*. Disponibile su Kaggle.
- [18] Kuss, D. J., & Griffiths, M. D. (2017). Social networking sites and addiction: Ten lessons learned. *International Journal of Environmental Research and Public Health*, 14(3), 311.
- [19] Levenson, J. C., Shensa, A., Sidani, J. E., Colditz, J. B., & Primack, B. A. (2017). Social media use before bed and sleep disturbance among young adults. *Preventive Medicine*, 105, 36–41.
- [20] Li, J., Mo, P. K. H., Wu, A. M. S., & Lau, J. T. F. (2020). Social networking addiction symptoms and associated psychosocial factors among Chinese adolescents. *Journal of Behavioral Addictions*, 9(3), 698–708.
- [21] Luo, T., Qin, L., Cheng, L., et al. (2021). Social networking sites addiction and associated psychological problems among Chinese college students: A nationwide study. *Journal of Behavioral Addictions*, 10(2), 363–374.
- [22] Marino, C., Gini, G., Vieno, A., & Spada, M. M. (2018). The associations between problematic Facebook use, psychological distress and well-being among adolescents and young adults: A systematic review and meta-analysis. *Journal of Affective Disorders*, 226, 274–281.
- [23] Marino, C., Vieno, A., Pastore, M., & Spada, M. M. (2018). Problematic Facebook use: The role of gender, personality and social norms. *Addictive Behaviors*, 82, 91–97.
- [24] Monacis, L., de Palo, V., Griffiths, M. D., & Sinatra, M. (2017). Social networking addiction, attachment style, and validation of the Italian version of the Bergen Social Media Addiction Scale. *Journal of Behavioral Addictions*, 6(2), 178–186.

- [25] Przybylski, A. K., Murayama, K., DeHaan, C. R., & Gladwell, V. (2013). Motivational, emotional, and behavioral correlates of fear of missing out. *Computers in Human Behavior*, 29, 1841–1848.
- [26] Rahmawati, I., & Putri, D. E. (2022). Family cohesion as a protective factor against problematic social media use among Indonesian adolescents during the COVID-19 pandemic. *Journal of Child and Family Studies*, 31, 2215–2227.
- [27] Reiss, F. (2013). Socioeconomic inequalities and mental health problems in children and adolescents: A systematic review. *Social Science & Medicine*, 90, 24–31.
- [28] Scott, H., Biello, S. M., & Woods, H. C. (2019). Social media use and adolescent sleep patterns: Cross-sectional findings from the UK Millennium Cohort Study. *BMJ Open*, 9, e031161.
- [29] Servidio, R. (2021). Self-control and problematic smartphone use: The role of family functioning. *Current Psychology*, 40, 4105–4114.
- [30] Twenge, J. M., & Campbell, W. K. (2018). Associations between screen time and lower psychological well-being among children and adolescents: Evidence from a population-based study. *Preventive Medicine Reports*, 12, 271–283.
- [31] University of Michigan School of Public Health. (2025). *Healthy Minds Study: College student depression, anxiety decline for third consecutive year*. News Release.
- [32] Vogel, E. A., Rose, J. P., Roberts, L. R., & Eckles, K. (2014). Social comparison, social media, and self-esteem. *Psychology of Popular Media Culture*, 3, 206–222.
- [33] Yu, D. J., Wing, Y. K., Li, T. M. H., & Chan, N. Y. (2024). The impact of social media use on sleep and mental health in youth: A scoping review. *Current Psychiatry Reports*, 26, 104–119.
- [34] Yusoff, M. S. B., Ahmad, A., & Isa, M. R. (2021). Social media addiction and its associated factors among Malaysian university students. *International Journal of Environmental Research and Public Health*, 18(22), 12098.
- [35] Zhang, J., Wang, Y., Zhou, L., Wu, J., Li, H., & Zhu, T. (2025). Correlations between social media addiction and anxiety, depression, FoMO, loneliness and self-esteem among students: A systematic review and meta-analysis. *PLOS ONE*, 20(1), e0281234.